

AgroSearch - Motor de Busca Inteligente

Desafio Integrador - Recuperação de Informação / PLN

1. Base de documentos

Doc1: A soja requer irrigação constante durante o período de floração para garantir a produtividade.

Doc2: O controle biológico de lagartas na soja pode ser feito com a vespa Trichogramma.

Doc3: A adubação verde com leguminosas melhora o nitrogênio no solo para o milho.

Doc4: Lagartas desfolhadoras causam grande prejuízo na cultura da soja e do algodão.

Doc5: A irrigação por gotejamento economiza água e é ideal para o cultivo orgânico.

2. Pipeline de pré-processamento

Doc1: Tokens=['A', 'soja', 'requer', 'irrigação', 'constante', 'durante', 'o', 'período', 'de', 'floração', 'para', 'garantir', 'a', 'produtividade']

Doc1: Normalizados=['a', 'soja', 'requer', 'irrigacao', 'constante', 'durante', 'o', 'periodo', 'de', 'floracao', 'para', 'garantir', 'a', 'produtividade']

Doc1: Sem stopwords=['soja', 'requer', 'irrigacao', 'periodo', 'floracao', 'garantir', 'produtividade']

Doc1: Stemmed=['soja', 'requer', 'irrigacao', 'periodo', 'floracao', 'garantir', 'produtividade']

Doc2: Tokens=['O', 'controle', 'biológico', 'de', 'lagartas', 'na', 'soja', 'pode', 'ser', 'feito', 'com', 'a', 'vespa', 'Trichogramma']

Doc2: Normalizados=['o', 'controle', 'biologico', 'de', 'lagartas', 'na', 'soja', 'pode', 'ser', 'feito', 'com', 'a', 'vespa', 'trichogramma']

Doc2: Sem stopwords=['controle', 'biologico', 'lagartas', 'soja', 'pode', 'feito', 'vespa', 'trichogramma']

Doc2: Stemmed=['controle', 'biologico', 'lagarta', 'soja', 'pode', 'feito', 'vesp', 'trichogramm']

Doc3: Tokens=['A', 'adubação', 'verde', 'com', 'leguminosas', 'melhora', 'o', 'nitrogênio', 'no', 'solo', 'para', 'o', 'milho']

Doc3: Normalizados=['a', 'adubacao', 'verde', 'com', 'leguminosas', 'melhora', 'o', 'nitrogenio', 'no', 'solo', 'para', 'o', 'milho']

Doc3: Sem stopwords=['adubacao', 'verde', 'leguminosas', 'nitrogenio', 'solo', 'milho']

Doc3: Stemmed=['adubacao', 'verde', 'leguminosa', 'nitrogenio', 'solo', 'milho']

Doc4: Tokens=['Lagartas', 'desfolhadoras', 'causam', 'grande', 'prejuízo', 'na', 'cultura', 'da', 'soja', 'e', 'do', 'algodão']

Doc4: Normalizados=['lagartas', 'desfolhadoras', 'causam', 'grande', 'prejuizo', 'na', 'cultura', 'da', 'soja', 'e', 'do', 'algodao']

Doc4: Sem stopwords=['lagartas', 'desfolhadoras', 'causam', 'prejuizo', 'cultura', 'soja', 'algodao']

Doc4: Stemmed=['lagarta', 'desfolhado', 'causam', 'prejuizo', 'cultur', 'soja', 'algodao']

Doc5: Tokens=['A', 'irrigação', 'por', 'gotejamento', 'economiza', 'água', 'e', 'é', 'ideal', 'para', 'o', 'cultivo', 'orgânico']

Doc5: Normalizados=['a', 'irrigacao', 'por', 'gotejamento', 'economiza', 'agua', 'e', 'e', 'ideal', 'para', 'o', 'cultivo', 'organico']

Doc5: Sem stopwords=['irrigacao', 'gotejamento', 'economiza', 'agua', 'cultivo', 'organico']

Doc5: Stemmed=['irrigacao', 'gotejam', 'economiz', 'agua', 'cultivo', 'organico']

3. Índice invertido

floracao: ['Doc1']

garantir: ['Doc1']

irrigacao: ['Doc1', 'Doc5']

periodo: ['Doc1']

produtividade: ['Doc1']

requer: ['Doc1']

soja: ['Doc1', 'Doc2', 'Doc4']

biologico: ['Doc2']

controle: ['Doc2']

feito: ['Doc2']

lagarta: ['Doc2', 'Doc4']

pode: ['Doc2']
trichogramm: ['Doc2']
vesp: ['Doc2']
adubacao: ['Doc3']
leguminosa: ['Doc3']
milho: ['Doc3']
nitrogenio: ['Doc3']
solo: ['Doc3']
verde: ['Doc3']
algodao: ['Doc4']
causam: ['Doc4']
cultur: ['Doc4']
desfolhado: ['Doc4']
prejuizo: ['Doc4']
agua: ['Doc5']
cultivo: ['Doc5']
economiz: ['Doc5']
gotejam: ['Doc5']
organico: ['Doc5']

4. Consulta e ranqueamento TF-IDF

Query: soja
Doc1: Score=0.072975
Doc4: Score=0.072975
Doc2: Score=0.063853
Doc3: Score=0.0
Doc5: Score=0.0

5. Conclusão

O índice invertido acelera a busca por termo e o TF-IDF ordena os documentos por relevância, permitindo ao técnico localizar rapidamente as informações mais úteis.